

Deep Learning-Based Automated Diagnosis of Intracranial Bleeding: A Paradigm Shift in Neurological Care

אבחון מבוסס למידה עמוקה של דימום תוך גולגולתי: שינוי פרדיגמה בטיפול נוירולוגי

שחר פסטרנק 205482045

צפיר גרבר 205939317

אדיר דמארי 316462241

תקציר

דימום תוך גולגולתי, בעיה בריאותית קריטית המחייבת טיפול רפואי מיידי, דורש אבחון מהיר ומדויק כדי להבטיח התערבות רפואית בזמן. במאמר זה, אנו מציגים את המאמצים המשותפים שלנו ברתימת הכוח העצום של למידה עמוקה לזיהוי דימום (CNN) וסגמנטציה (פילוח) ע"י K-means כדי לקדם את האבחנה של דימום תוך גולגולתי. בעבודה כזו מגובש, מינפנו את המומחיות הקולקטיבית שלנו בעיבוד מוקדם של נתונים, פיתוח מודלים של למידה עמוקה ואשכולות K-means כדי ליצור פתרון חזק ויעיל. באמצעות פרויקט זה, אנו שואפים לקדם אבחון רפואי מהיר ולשפר את זמן תוצאות הבדיקות על ידי זיהוי מהיר של הדימום באמצעות למידה עמוקה וכתוצאה מכך להביא לטיפול בזמן בדימום תוך גולגולתי. מאמר זה שופך אור על היתרונות של עבודת צוות וחדשנות בהתמודדות עם אתגרים רפואיים קריטיים, ומציע תובנות לגבי העתיד של שירותי בריאות בעזרת בינה מלאכותית.

מבוא

דימום תוך גולגולתי, מצב המאופיין בדימום בתוך הגולגולת, מהווה אתגר בריאותי חמור וזהו מצב שעלול לסכן חיים הדורש טיפול רפואי מיידי ומיוחד. זיהוי מדויק של המיקום והסוג של הדימום התוך גולגולתי הוא שלב קריטי בהבטחת הטיפול גם מבחינת הזמן וגם מבחינת היעילות. עם זאת, תהליך האבחון המסורתי, המסתמך על מומחים בעלי הכשרה גבוהה לבדיקת תמונות רפואיות של גולגולת המטופל, יכול להיות מורכב וגוזל זמן, ולהוביל לעיכובים בטיפול ולתוצאות לא אופטימליות.

דימום תוך גולגולתי תורם לכ-10% ממקרי השבץ בארצות הברית, כאשר השבץ עצמו מדורג כגורם המוות החמישי במדינה. זה מדגיש את המשמעות של פיתוח שיטות מתקדמות ויעילות לאבחון דימום תוך גולגולתי, שכן גילוי מוקדם וסיווג מדויק של סוגי דימומים יכולים לשפר משמעותית את הפרוגנוזה ואת שיעורי ההישרדות של המטופל.

כדי להתמודד עם האתגרים שמציב תהליך האבחון הנוכחי, השתמשנו בפרויקט שלנו בטכניקות למידה עמוקה מתקדמות בניתוח הדמיה רפואית. המטרה העיקרית היא לפתח אלגוריתם למידת מכונה חזק ומדויק. אלגוריתם זה יוכל לזהות אוטומטית את הנוכחות, המיקום והסוג של דימום תוך גולגולתי בתמונות CT, ומציע תמיכה חשובה מאין כמותה לאנשי מקצוע בתחום הבריאות.

המטרה המרכזית של מחקר זה היא ליצור מודל מבוסס למידה עמוקה מדויק ויעיל, תוך שימוש במערך הנתונים שלנו כדי להבחין בדפוסים מורכבים בתוך הנתונים ולשפר את דיוק האבחון שלו. מחקר זה שואף לחולל מהפכה בתחום הניירולוגיה על ידי האצת תהליך האבחון והקלה על תוצאות טובות יותר של המטופל.

השפעתו הפוטנציאלית של פרויקט זה היא עצומה, אלגוריתם אוטומטי מדויק ויעיל ביותר לאבחון דימום תוך גולגולתי יכול להוביל לשינוי פרדיגמה בטיפול הניירולוגי. על ידי זירוז תהליך האבחון והטיפול, ספקי שירותי בריאות יכולים ליזום מיידיית התערבויות ממוקדות, למזער את הסיכון לסיבוכים ואפשר להציל חיים. יתרה מכך, האוטומציה של תהליך זה תקל על העומס על מומחים רפואיים, תאפשר להם להתמקד במשימות קריטיות של קבלת החלטות וייעול היעילות הכוללת של שירותי הבריאות.

פרויקט המחקר שלנו מסתמך על מערך נתונים הכולל 2500 תמונות של רקמות רכות (מוח). מערך הנתונים משמש כקלט למודל הלמידה העמוקה המתקדם שלנו, שנועד להפוך את האבחנה של דימום תוך גולגולתי לאוטומטי. הפלט של המודל מובנה בשני שלבים, כאשר השלב הראשון כולל רשת עצבית קונבולוציונית (CNN) האחראית לסיווג בינארי, הקובעת אם יש נוכחות כלשהי של דימום בתמונות המוח, והשלב השני לבצע סגמנטציה (פילוח) לזיהוי סוג דימום.

שלב ראשון: סיווג בינארי לזיהוי דימום

בשלב הראשוני של הפרויקט שלנו בנינו CNN. רשת קונבולוציה שמסווגת אם יש דימום או לא. התוצאה של שלב זה היא קריטית, מכיוון שהיא משמשת כמסנן ראשוני לזיהוי מקרים שבהם נדרש ניתוח נוסף לאבחון מדויק.

אם ה-CNN מסווגת תמונה מוחית כ"דימום קיים", האלגוריתם ממשיך לשלב הבא של התהליך, הכולל אבחנה של סוג דימום ע"י סגמנטציה כדי לזהות את סוג הדימום הספציפי.

שלב שני: סגמנטציה לזיהוי סוג דימום

לאחר זיהוי נוכחות הדימום בתמונות המוח, האלגוריתם מבצע פילוח כדי לסווג את הדימום לאחד מחמשת הסוגים השונים. כל סוג מייצג מיקום מובהק של הדימום התוך גולגולתי, המאפשר לאנשי מקצוע בתחום הבריאות למקד את הטיפול בצורה יעילה יותר בהתבסס על הסוג הספציפי.

נציג בקצרה את 5 סוגי הדימום שאליהם התייחסנו בפרויקט :

Epidural-

דימום אפידורלי מתרחש כאשר יש דימום בין המשטח הפנימי של הגולגולת לשכבת ההגנה החיצונית ביותר של המוח. סוג זה של דימום נגרם לרוב מפגיעות ראש טראומטיות, כגון שברים בגולגולת או פגיעות משמעותיות אחרות בראש. הסיבה השכיחה ביותר היא קריעה של עורק, בדרך כלל עורק קרום המוח האמצעי, אשר מוביל להצטברות של דם בתוך החלל האפידורלי.

Subdural-

דימום המתרחש בין שכבת ההגנה החיצונית של המוח לבין הממברנה הארכנואידית (השכבה האמצעית). בניגוד לדימומים אפידורליים, שטפי דם מסוג זה קשורים לרוב לדימום ורידי, הנוטה להתפתח בצורה הדרגתית יותר. לעתים קרובות הם תוצאה של טראומה בראש שגורמת למתיחה וקריעה של ורידים המגשרים בין המוח לשכבת ההגנה החיצונית של המוח. המטומות תת-דוראליות יכולות להשתנות בגודלן ועשויות להופיע עם מגוון רחב של תסמינים, בהתאם לקצב הדימום ולמקום הפנוי להצטברות דם.

Subarachnoid-

דימום שמתרחש כאשר יש דימום לתוך החלל שבין הממברנה הארכנואידית (השכבה האמצעית) לפיה מאטר (השכבה הפנימית ביותר) של המוח. הגורם השכיח ביותר לדימום מסוג זה הוא קרע של מפרצת תוך גולגולתית, אזור מוחלש בדופן של עורק מוחי. טראומה, מומים עורקים (AVMs) או מומים אחרים בכלי הדם יכולים להוביל גם לדימום שכזה. אחד מסימני ההיכר של דימום זה הוא כאב ראש פתאומי וחמור, המתואר לעתים קרובות כ"כאב הראש הגרוע ביותר בחיי". תסמינים אחרים עשויים לכלול בחילות, הקאות, נוקשות צוואר ואובדן הכרה.

Intraparenchymal-

דימום שמתייחס לדימום המתרחש ישירות בתוך רקמת המוח עצמה. זה קשור בדרך כלל למצבים כמו יתר לחץ דם (לחץ דם גבוה) או מומים בכלי הדם. שטפי דם תוך פרנקימליים עלולים להוביל לנזק מקומי במוח, וכתוצאה מכך לחסרי נוירולוגיים המבוססים על האזור הפגוע. התסמינים עשויים לכלול כאב ראש חמור, ליקויים נוירולוגיים מוקדיים (כגון חולשה, חוסר תחושה או קושי בדיבור), שינוי בהכרה והתקפים.

Intraparenchymal-

דימום תוך-חדרי כרוך בדימום בתוך מערכת החדרים של המוח, המורכבת מחדרים מלאי נוזלים. סוג זה של דימום קשור לעתים קרובות לתינוקות פגים, במיוחד אלה עם משקל לידה נמוך מאוד. כלי הדם השבריריים במוח המתפתח של פגים עלולים להיקרע ולגרום להצטברות דם בחדרים. דימום תוך-חדרי עלול להוביל ללחץ מוגבר בתוך המוח, שעלול להפריע למחזור נוזלי המוח השדרתי הרגיל ולהוביל להידרופלוס (הצטברות עודף נוזלים במוח). תינוקות עם דימום תוך-חדרי עלולים להפגין עייפות, האכלה לקויה ועיכובים בהתפתחות.

כחלק מהתהליך של הכנת הדאטה ביצענו מגוון פעולות , נסביר ונפרט אותן כאן :

ניקוי עמודות לא רלוונטיות - כאשר עובדים עם מערך נתונים, בהרבה מקרים ישנן עמודות או מאפיינים שונים שעשויים לא להיות רלוונטיים למשימה שעל הפרק, במקרה זה, אבחון דימום תוך גולגולתי. עמודות לא רלוונטיות אלו עשויות להכיל מידע שאינו תורם לתהליך הסיווג ואף עשוי להכניס רעש לנתונים. הסרת עמודות כאלה מיעלת את מערך הנתונים והופכת אותו לממוקד יותר במידע החיוני הדרוש לאימון הרשת (CNN).

שינוי שמות עמודות - חשוב שיהיו שמות ברורים ועקביים לעמודות של מערך הנתונים. על ידי שינוי שמות העמודות, אנו מזהים שהנתונים מאורגנים היטב וקלים יותר להבנה. שלב זה מסייע גם בשמירה על שלמות הנתונים והימנעות מבלבול במהלך שלבי הכנת הנתונים וההכשרה.

קריאת כל התמונות של כל המטופלים - מאחר שמטרת הפרויקט היא לאבחן דימום תוך גולגולתי באמצעות תמונות רפואיות, קריאת כל התמונות הזמינות של כל מטופל היא חיונית. תמונות אלו משמשות כנתוני הקלט העיקריים עבור מודל CNN. על ידי קריאת כל התמונות, החוקרים יכולים לבנות מערך נתונים מקיף ומגוון אשר לוודא את המקרים השונים של דימום תוך גולגולתי, הסוגים השונים שלו, ופוטנציאליים שלבים שונים של המצב.

מחיקת תמונות ממופות שאינן שייכות - בתהליך הכנת מערך הנתונים, רצינו להבטיח עקביות בנתונים ולהימנע מהכנסת נתונים לא רלוונטיים. הסרנו תמונות שאינן רלוונטיות למשימת היעד של המודל (אבחון דימום תוך גולגולתי). בכך וידאנו שמערך הנתונים המזווג (תמונות עם תוויות מתאימות) נקי ומתאים לאימון ה-CNN.

יצירת מערך נתונים מזווג (שיוך תמונה-תווית) - במשימות למידה מפוקחות כמו סיווג תמונות, חיוני להחזיק מערך נתונים שבו כל תמונה משויכת לתווית המתאימה לה (כלומר, האם היא מייצגת דימום תוך גולגולתי והסוג הספציפי שלה אם קיים). יצירת מערך נתונים זוגי כזה מאפשרת ל-CNN ללמוד את הקשרים בין התמונות והשיעורים התואמים להן במהלך האימון. זהו הבסיס לתהליך הלמידה, שכן המודל מתאים את הפרמטרים שלו בהתבסס על צמדי הקלט-תמונה ותוויות כדי לבצע תחזיות מדויקות במהלך ההסקה.

עבודות קשורות שראינו בנושא :

1. ראינו עבודה בקאגל שבה השתמשו בתמונות המוח והמירו אותן לתמונות תלת ערוציות , יישמו DWT (טכניקה מתמטית לעיבוד אותות ודחיסת תמונה). שינו את גודל התמונות ל 256×256 , הקצו 20 תמונות לסט מבחן , את התמונות הנותרות חילקו 85% לסט אימון ו 15% לוולידציה (אימות) , הם השתמשו בארכיטקטורת למידה עמוקה מסוג Densenet 121 וכמו כן השתמשו באופטימיזר 'אדם' , הם נרמלו תמונות וכן הוסיפו תמונות למערך הנתונים.
2. כמו כן ראינו עוד עבודה שבה מי שניסה לחזות לא עבד בצורה נכונה בכלל ולא הגיע לתוצאות שניתן היה לבדוק בכלל .

גישת הלמידה העמוקה:

- הפרויקט מחולק לשני שלבים האחד זיהוי האם קיים דימום ובו יישמנו מודל CNN ובשני מסווגים לסוג דימום מסוים מתוך 5 אפשריים.
- התחלנו בעיבוד הנתונים וקראנו את הקובץ CSV המכיל מידע על החולים וגם את התמונות המתאימות להם . התמונות מאורגנות בתתי תיקיות לכל מטופל תיקיה . לאחר מכן עוברים על כל הדאטה קוראים כל תמונה ממירים אותה לגווני אפור ומשנים את גודלה ל 64×64 .
- לאחר מכן נרמלנו את התמונות ע"י חלוקה ב 255 ואז חילקנו את הדאטה לסט אימון וסט מבחן בחלוקה של 80/20 .
- לאחר מכן בנינו את המודל שהוא רשת עצבית קונבולוציונית (CNN) לסיווג בינארי האם קיים שטף דם או לא . המודל מורכב מהשכבות הבאות :
1. שכבות Conv2D: שלוש שכבות קונבולוציה בגודל 32, 64, 128, בכל אחת משתמשים בקרנל בגודל 3×3 ובפונקציית אקטיבציה מסוג ReLU.
 2. שכבות MaxPooling2D: שלוש שכבות עם פילטרים בגודל 2×2 . (הפחתת הממדים תוך שמירה על התכונות החשובות ביותר) .
 3. שכבה שטוחה: משטיחה את התכונות הדו-ממדיות לווקטור דו-ממדי .
 4. שכבות צפופות (Dense): שתי שכבות צפופות האחת עם 64 ניוונים ופונקציית אקטיבציה מסוג ReLU והשנייה עם ניוירן בודד ופונקציית אקטיבציה מסוג סיגמואיד. השכבה האחרונה בעלת הניוירן הבודד מביאה לנו את הסיווג הבינארי בהתבסס על פונקציית ההפעלה של הסיגמואיד היא מסווגת לנו האם קיים דימום או לא.
- כמו כן עשינו שימוש ב - Adam Optimizer , שהוא אלגוריתם אופטימיזציה של קצב למידה אדפטיבי. פונקציית האובדן המשמשת לסיווג בינארי היא 'binary_crossentropy' , ומדד הדיוק משמש לניטור ביצועי המודל. לאחר מכן, המודל מאומן על סט האימון ל - 35 Epochs - batch_size=32 .
- בשלב השני אנו לוקחים את הפלט של רשת הקונבולוציה מהשלב הראשון ואנו מסווגים את סוג הדימום לפי K - Means Algorithm .

שיקולים בבחירות שהיו לנו בעת מימוש המודל :

- הארכיטקטורה :

הארכיטקטורה שנבחרה לשלב הראשוני שבו אנו חוזים האם קיים דימום או לא היא ארכיטקטורת CNN פשוטה יחסית, המתאימה למשימות סיווג בינארי כמו זיהוי שטפי דם. מספר השכבות וסוגיהן הוחלט על סמך מספר שיקולים:

1. **פשטות:** הארכיטקטורה אינה מורכבת מדי, מה שיכול להיות יתרון כאשר עובדים עם כמות נתונים יחסית קטנה. מודלים פשוטים יותר נוטים פחות להתאמת יתר ודורשים פחות משאבי חישוב.
2. **גודל תמונה:** גודל תמונת הקלט הוא 64×64 פיקסלים ושכבות Conv2D מתאימות לחילוץ תכונות רלוונטיות מגודל קלט זה ביעילות רבה.
3. **עומק הרשת:** הדרך בה בחרנו לממש את רשת הנירונים הגדלת שכבות מ-32 ל-64 ואז ל-128 סיפקה למודל את האפשרות ללכוד דפוסים מורכבים יותר בנתונים.
4. **MaxPooling:** שכבות MaxPooling2D מפחיתות ממדים מרחביים ומתמקדות בתכונות האינפורמטיביות ביותר ובכך גם החישוב הופך לקל יותר.
5. **Dense:** שתי השכבות הצפופות (64 ניורונים ונירון 1) בסוף המודל מתאימות לסיווג בינארי, כאשר פונקציית ההפעלה הסיגמואידית משמשת לפלט הסופי.

- קצב הלמידה :

בספריית Keras שבה השתמשנו נעשה שימוש ב Adam Optimizer, המשלב קצבי למידה אדפטיביים. הוא מתאים אוטומטית את קצב הלמידה במהלך האימון ומאפשר התכנסות מהירה יותר ואימון יציב יותר.

- שיטת האופטימיזציה :

שיטת האופטימיזציה בה נעשה שימוש היא ה-Adam. אלגוריתם אופטימיזציה פופולרי לאימון מודלים של למידה עמוקה.

- פונקציית המחיר

פונקציית ההפסד שבה השתמשנו היא Binary cross entropy זוהי פונקציה שמתאימה למשימות מסוג זה של סיווג בינארי, כאשר הפלט הוא ערך יחיד המייצג את ההסתברות של המחלקה החיובית, פונקציה מחיר זו מענישה שגיאות גדולות יותר בעונשים כבדים יותר.

- כוונן ההיפר-פרמטרים:

במהלך הכנת הפרויקט הרצנו את המודל עם שינויים שונים בכדי לראות איך נקבל את התוצאות הטובות ביותר. כחלק מהתאמת ההיפר פרמטרים התאמנו את גודל התמונות בקלט, שינינו את גודל השכבות, כמו כן את גודל השכבה שמקושרת היטב של ה-64, את קצב הלמידה ואת הסף לחיזוי (threshold), שינוי של מס ה epochs ושל ה batch size.

דיון:

בהתבסס על התוצאות והעבודה שנעשתה עד כה, ישנם מספר תחומים לעבודה נוספת וגישות עתידיות פוטנציאליות לשיפור הפרויקט:

1. **הגדלת נתונים:** ניתן ליישם טכניקות של data augmentation כדי לשפר את התוצאות וכדי לעזור למודל להכליל טוב יותר.
2. **Transfer learning:** היינו רוצים לנסות להשתמש במודלים שהוכשרו מראש, במיוחד כאלו שהוכשרו על מערכי הדמיה רפואיים גדולים, בהינתן יותר זמן היינו מחפשים מודלים מתאימים ואולי עם כוונן ההיפר פרמטרים שלהם היינו יכולים להגיע לתוצאות טובות יותר.
3. **הערכה על מערכי נתונים חיצוניים:** בהינתן יותר זמן היינו רוצים לנסות לבחון את המודל על מערכי נתונים חיצוניים, אם היינו יכולים להשיג גישה לנתונים של בתי חולים או מקורות שונים בכדי להעריך את ביצועי המודל בעולם האמיתי.
4. **שיתוף פעולה עם אנשי מקצוע:** בסופו של דבר כל נושא הפרויקט הוא רפואי ולכן היינו רוצים לאמת את המודל עם מומחים רפואיים, ע"י שיתוף פעולה עם מומחים מהתחום הזה אנו נוכל להעריך את הדיוק והאמינות של המודל בצורה הכי טובה.

מסקנות:

בהתבסס על העבודה שנעשתה במסגרת הפרויקט, ניכר כי יישום הטכניקות של הלמידה העמוקה, ה CNN לסיווג ראשוני והסגמנטציה של ה K-Means לסיווג סוג הדימום נראה טוב והגיע לתוצאות דיי טובות.

עם זאת, יש להסיק את מסקנות הפרויקט בזהירות, שכן מספר גורמים משפיעים על הביצועים והישימות של המודל:

1. **איכות וגודל מערך הנתונים:** הדיוק והאמינות של המודל תלויים במידה רבה באיכות, במגוון ובגודל של מערך ההדרכה. מערך נתונים גדול ומגוון יותר עם תוויות אמת קרקע מדויקות יכול לשפר את הכללת המודל. (במקרה שלנו הכמות היא לא גדולה וכן לא מאוזנת כי רוב המטופלים לא חולים ז"א ללא דימום בכלל).
2. **יישום בעולם האמיתי:** בשביל להגיע למצב שיהיה אפשר להשתמש במודל כזה בעולם האמיתי יש צורך בבדיקות נרחבות על נתוני חולים כדי להבטיח שהמודל מדויק מספיק ליישום.
3. **פרשנות:** טכניקות של למידה עמוקה נחשבות לרוב לכאלה שלא ניתנות לפירוש, וזה דבר שהוא חיוני עבור יישומים רפואיים בכדי שרופאים ואנשי מקצוע בתחום הבריאות יאמינו בזה ויסקימו לקבל את זה.

לסיכום, העבודה עד כה מציגה תוצאות מבטיחות, אך נדרשים מאמצים נוספים כדי לשפר עוד יותר את הדיוק, החוסן והישימות של המודל. שיתוף פעולה עם מומחים רפואיים וטיפול במגבלות פוטנציאליות יכול לסלול את הדרך לשילוב מוצלח של פתרונות מבוססי בינה מלאכותית בתחום הבריאות.

תרומה של כל סטודנט:

כצוות מגובש שעבד על הפרויקט, החלטנו לעבוד בשיתוף פעולה הדוק ולגשת למשימות באופן קולקטיבי במקום לחלק אותן לתפקידים ולתת לכל אחד משימה שונה מכיוון שהאמנו בכוחם של שיתוף פעולה ועבודת צוות. ההחלטה שלנו לעבוד יחד כצוות נבעה מאמונה שעל ידי שילוב הכישורים והידע שלנו נוכל להגיע לתוצאות טובות יותר מאשר עבודה פרטנית.

על ידי אימוץ גישה שיתופית זו, טיפחנו סביבה של תקשורת פתוחה, תמיכה הדדית ומשוב מתמשך. רוח שיתופית זו אפשרה לנו למנף את המומחיות הייחודית של כל חבר צוות בתחומים שונים, כגון עיבוד מוקדם של נתונים, עיצוב ארכיטקטורת למידה עמוקה, גמנטציה של K-means וניתוח תוצאות.

כתוצאה מכך, הצלחנו לנצל את החוזקות של כל חבר, להשלים את החולשות אחד של השני ולשמור על רמה גבוהה של חדשנות לאורך כל הפרויקט. העבודה המשותפת שלנו גם טיפחה תחושת בעלות ואחריות משותפת, והובילה למסירות קולקטיבית למציאות ולנכונות לעשות מאמצים נוספים כדי להבטיח את הצלחת הפרויקט.

בסופו של דבר, הגישה המשותפת שלנו הוכיחה את עצמה כמסייעת בהשגת פתרון מקיף לאבחון של דימום תוך גולגולתי. זה יצר אווירה חיובית ומעודדת שבה כולנו הרגשנו אחריות להצלחת הפרויקט. הגישה המשותפת שלנו הובילה לפתרון מקיף לאבחון דימום תוך גולגולתי, ואנו גאים במה שהשגנו יחד.